



รายงาน

การพัฒนาระบบตรวจจับการสวมหมวกนิรภัยในโรงงานอุตสาหกรรม โดยใช้การประมวลผลภาพ
Development of a Computer Vision-Based System for Detecting Industrial Helmet Usage

จัดทำโดย

- | | | |
|--------------|----------------|------------|
| 1.6814400910 | นางสาวกนิษฐา | สมบุญ |
| 2.6814400952 | นางสาวรวิรัตน์ | ยาวิชัย |
| 3.6814450038 | นายฐกร | นิยมสันติ |
| 4.6814450216 | นายอัศวิสต์ | มหายศนันท์ |
| 5.6814450224 | นางสาวอุษมา | บุญสำเร็จ |
| 6.6814450241 | นายณัฐณภัทร | เพชรเรือง |

เสนอ

ผศ.ดร.ชาคริต วังโรภาส

รายงานนี้เป็นส่วนหนึ่งของรายวิชา 01418564 การเรียนรู้เชิงลึกและการประยุกต์

ภาคเรียนที่ 1 ปีการศึกษา 2568

ภาควิชาวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์

มหาวิทยาลัยเกษตรศาสตร์

คำนำ

รายงานฉบับนี้เป็นส่วนหนึ่งของรายวิชา 01418564 การเรียนรู้เชิงลึกและการประยุกต์ ภาคเรียนที่ 1 ปีการศึกษา 2568 มีวัตถุประสงค์เพื่อพัฒนา ระบบตรวจจับการสวมใส่หมวกนิรภัยของพนักงานในสายการผลิต โดยประยุกต์ใช้เทคโนโลยี คอมพิวเตอร์วิทัศน์ (Computer Vision) แบบ Real-time ร่วมกับแนวทางการเรียนรู้เชิงลึกสำหรับการตรวจจับวัตถุ เพื่อให้ การเฝ้าระวังด้านความปลอดภัยมีความรวดเร็ว ต่อเนื่อง และแม่นยำยิ่งขึ้นในบริบทโรงงานอุตสาหกรรม

เนื้อหาในรายงานครอบคลุมตั้งแต่การศึกษาแนวคิดและงานวิจัยที่เกี่ยวข้อง การออกแบบสถาปัตยกรรมระบบ การเตรียมและประมวลผลข้อมูลภาพ วิธีการฝึกและปรับแต่งโมเดล การทดสอบประสิทธิภาพเชิงปริมาณและเชิงปฏิบัติการ ตลอดจนการวิเคราะห์ผลและข้อเสนอแนะในการนำไปใช้จริง ระบบที่พัฒนาขึ้นมุ่งหวังให้สามารถตรวจจับได้แบบ Real-time ลดข้อผิดพลาดจากการตรวจสอบด้วยสายตาของมนุษย์ เพิ่มประสิทธิภาพการจัดการความปลอดภัย และเป็นพื้นฐานในการ ต่อยอดสู่ระบบแจ้งเตือนหรือบูรณาการกับโครงสร้างพื้นฐานของโรงงานในอนาคต

คณะผู้จัดทำหวังเป็นอย่างยิ่งว่ารายงานฉบับนี้จะเป็นประโยชน์ต่อผู้ที่สนใจด้าน Computer Vision ความปลอดภัย ในการทำงาน และ การประยุกต์ใช้การเรียนรู้เชิงลึกในอุตสาหกรรม ทั้งในเชิงวิชาการและเชิงปฏิบัติ หากมีข้อเสนอแนะใด ๆ เพื่อเพิ่มคุณภาพของงาน ทางคณะผู้จัดทำขอน้อมรับไว้ด้วยความยินดีเพื่อพัฒนางานให้ดียิ่งขึ้นต่อไป

คณะผู้จัดทำ

สารบัญ

คำนำ.....	ก
สารบัญ.....	๗
สารบัญรูปภาพ.....	ฉ
สารบัญตาราง	๗
บทที่ 1	1
บทนำ	1
1. ที่มาและความสำคัญของปัญหา.....	1
2. ปัญหาวิจัย (Research Problem).....	2
3. คำถามวิจัย (Research Questions).....	2
4. วัตถุประสงค์ของการวิจัย.....	2
5. สมมติฐานการวิจัย	2
6. รายละเอียดเกี่ยวกับองค์กร	2
7. มาตรฐานการบริหารจัดการ	3
8. ขอบเขตการวิจัย	3
9. ประโยชน์ที่คาดว่าจะได้รับ.....	3
9.1 เชิงวิชาการ (Academic Benefits)	3
9.2 เชิงปฏิบัติ (Practical Benefits)	3
10. แผนดำเนินงานและระยะเวลาปฏิบัติงาน	4
11. อุปกรณ์และเครื่องมือที่ใช้ในการพัฒนา	4
11.1 ฮาร์ดแวร์ที่ใช้ในการพัฒนา	4
11.2 ซอฟต์แวร์ที่ใช้ในการพัฒนา	4
บทที่ 2	5
เอกสารและงานวิจัยที่เกี่ยวข้อง	5
2.1 ทฤษฎีและแนวคิดที่เกี่ยวข้อง.....	5

2.1.1 คอนโวลูชันแนลนิวรัลเน็ตเวิร์ก (Convolutional Neural Network: CNN)	5
2.1.2 แนวคิดของโมเดล YOLO (You Only Look Once)	6
2.1.3 ทฤษฎีของการมองเห็นของคอมพิวเตอร์ (Computer Vision Theory)	7
2.2 ตัวชี้วัดการประเมินประสิทธิภาพ (Evaluation Metrics).....	8
2.2.1 Precision (ความเที่ยงตรง).....	8
2.2.2 Recall (ความไวในการตรวจจับ)	8
2.2.3 Mean Average Precision (mAP).....	8
2.2.4 Confusion Matrix.....	9
2.2.5 การประยุกต์ใช้ในงานตรวจจับการสวมหมวกนิรภัย	9
2.3 แนวคิดเกี่ยวกับมาตรฐานสากล (International Standards).....	9
2.3.1 มาตรฐาน ISO 45001 และกรอบการจัดการด้านอาชีวอนามัยและความปลอดภัย.....	9
2.3.2 การประยุกต์ใช้วิธีทัศน์คอมพิวเตอร์กับความปลอดภัย: การตรวจจับการสวมหมวกนิรภัย	10
2.4 การทบทวนวรรณกรรม	11
2.4.1 งานของ Zhang และคณะ (2025)	11
2.4.2 งานของ Deng (2024).....	11
บทที่ 3	12
วิธีดำเนินการวิจัย	12
3.1 รูปแบบการวิจัย (Research Design)	12
3.2 ประชากรและกลุ่มตัวอย่าง (Population and Sample).....	12
3.2.1 ประชากร (Population)	12
3.2.2 กลุ่มตัวอย่าง (Sample).....	12
3.3 การเก็บ และ เตรียมข้อมูล (Data Collection and Pre-processing)	13
3.3.1 แหล่งข้อมูล	13
3.3.2 เกณฑ์คัดเลือกภาพ	13
3.3.3 นิยามคลาสข้อมูล (Class Definitions)	13
3.4 การเตรียมข้อมูล (Pre-processing)	13

3.4.1 Annotation	13
3.4.2 การปรับแต่งภาพ (Image Adjustment).....	13
3.4.3 Data Augmentation	14
3.4.4 การแบ่งชุดข้อมูล (Dataset Splitting).....	14
3.5 แผนภาพกระบวนการวิจัย (Workflow Diagram)	14
3.6 การสร้างเครื่องมือในการวิจัย (Research Instruments)	15
3.6.1 แบบจำลองที่ใช้ในการตรวจจับวัตถุ	15
3.6.2 การปรับปรุงและฝึกโมเดล (Transfer Learning and Fine-tuning).....	15
3.6.3 ทรัพยากรที่ใช้ในการพัฒนา	15
3.7 การประเมินผล (Model Evaluation).....	16
3.7.1 Precision	16
3.7.3 Mean Average Precision (mAP).....	16
3.7.4 Confusion Matrix.....	16
3.8 ขั้นตอนการประเมินผล.....	16
บทที่ 4	17
ผลการดำเนินงาน.....	17
4.1 ความหมายของตัวแปร	17
4.2 ผลการฝึกฝนโมเดล	18
4.3 การประเมินประสิทธิภาพการตรวจจับวัตถุ.....	19
4.3.1 mAP (Mean Average Precision).....	19
4.3.2 Precision และ Recall.....	20
4.4 การประเมินประสิทธิภาพการจำแนกประเภท	21
4.4.1 Confusion Matrix.....	21
4.5 ผลการทดสอบการทำงานของระบบในสภาพแวดล้อมจริง (System Integration and Real-Time Testing).....	22
4.5.1 ความเร็วในการประมวลผล (Processing Speed - FPS)	22
4.5.2 ผลการทำงานในสถานการณ์ต่างๆ	22

4.5.3 ข้อผิดพลาดที่เกิดขึ้น (Failure Cases/Limitations).....	23
บทที่ 5.....	24
สรุปผลการวิจัย อภิปราย และข้อเสนอแนะ	24
5.1 สรุปผลการวิจัย	24
5.2 ปัญหาที่พบ.....	25
5.3 ข้อเสนอแนะ.....	25
5.4 ข้อจำกัด	25

สารบัญรูปภาพ

ภาพที่ 1 สูตร Precision	8
ภาพที่ 2 สูตร Recall	8
ภาพที่ 4 Confusion Matrix.....	9
ภาพที่ 5 แผนภาพกระบวนการวิจัย	14
ภาพที่ 6 Train Losses	18
ภาพที่ 7 Valodation Losses	18
ภาพที่ 8 mAP curves (Val).....	19
ภาพที่ 9 Validation Precision/ Recall	20
ภาพที่ 10 Processing Speed - FPS.....	22
ภาพที่ 12 มุมกล้องที่แตกต่างกัน.....	23
ภาพที่ 13 ข้อผิดพลาดที่เกิดขึ้น	23

สารบัญตาราง

ตารางที่ 1 แผนดำเนินงานและระยะเวลาปฏิบัติงาน.....	4
ตารางที่ 2 กลุ่มตัวอย่าง.....	13
ตารางที่ 3 ความหมายของตัวแปร.....	17
ตารางที่ 4 Confusion Matrix.....	21
ตารางที่ 5 Normalized Confusion Matrix	21

บทที่ 1

บทนำ

1. ที่มาและความสำคัญของปัญหา

ในกระบวนการผลิตของโรงงานอุตสาหกรรม โดยเฉพาะโรงงานผลิตชิ้นส่วนรถยนต์ ความปลอดภัยของพนักงานถือเป็นปัจจัยสำคัญที่ไม่อาจละเลยได้ การปฏิบัติตามมาตรการด้านความปลอดภัย เช่น การสวมใส่อุปกรณ์ป้องกันนิรภัย (Personal Protective Equipment: PPE) เป็นข้อกำหนดที่ทุกพนักงานจำเป็นต้องปฏิบัติตาม โดยเฉพาะ “หมวกนิรภัย” ซึ่งจัดเป็นอุปกรณ์สำคัญที่ช่วยลดความเสี่ยงในการบาดเจ็บบริเวณศีรษะจากการทำงาน

ปัจจุบันการตรวจสอบการสวมใส่อุปกรณ์ป้องกันนิรภัยในโรงงานส่วนใหญ่ยังคงอาศัยการตรวจสอบด้วยสายตาของเจ้าหน้าที่ตรวจสอบความปลอดภัย (Safety Officer) เป็นหลัก วิธีการดังกล่าวแม้จะเป็นมาตรการพื้นฐานที่ใช้กันทั่วไป แต่ก็มีข้อจำกัดหลายประการ ข้อแรก คือความผิดพลาดที่เกิดจากมนุษย์ (Human Error) เช่น เจ้าหน้าที่อาจมองไม่เห็นหรือหลุดออกจากการตรวจสอบในบางช่วงเวลา ข้อต่อมา คือความล่าช้าในการตรวจสอบ (Time-consuming) โดยเฉพาะพนักงานอาจมีจำนวนมากและต้องตรวจสอบทีละคนทำให้สิ้นเปลืองเวลา และข้อสุดท้าย คือความไม่ต่อเนื่อง (Inconsistency) เนื่องจากขึ้นอยู่กับระดับความเข้มงวดของเจ้าหน้าที่แต่ละคน อาจมีความผ่อนปรน ซึ่งส่งผลให้มาตรการความปลอดภัยลดทอนประสิทธิภาพ

จากข้อมูลภายในโรงงานผลิตชิ้นส่วนรถยนต์ พบว่าการตรวจสอบพนักงานแต่ละคนใช้เวลาเฉลี่ย 30 วินาที โดยพนักงานแบ่งการทำงานออกเป็นสองกะได้แก่ กะเช้าตั้งแต่เวลา 08.00 ถึง 17.00 นาฬิกา มีจำนวนพนักงาน 358 คน และกะดึกตั้งแต่เวลา 21.00 ถึง 06.00 นาฬิกา มีจำนวนพนักงาน 142 คน เมื่อรวมทั้งสองกะมีพนักงานทั้งสิ้น 500 คนต่อวัน ทำให้ต้องใช้เวลาในการตรวจสอบไม่น้อยกว่า 2 ชั่วโมงต่อกะการทำงาน และยังพบว่า มีพนักงานเฉลี่ยประมาณ 20 คนต่อวันหรือมีพนักงาน 10 คนต่อกะ ที่ไม่ปฏิบัติตามข้อกำหนดในการสวมหมวกนิรภัยก่อนเข้าสู่สายการผลิต ซึ่งสะท้อนให้เห็นถึงความเสี่ยงด้านความปลอดภัยที่ยังคงมีอยู่ในกระบวนการทำงาน

ด้วยเหตุนี้จึงมีความจำเป็นในการพัฒนาระบบตรวจจับการสวมหมวกนิรภัย โดยอาศัยเทคโนโลยีการประมวลผลภาพ (Computer Vision) แบบ Real-time เพื่อช่วยให้การตรวจสอบเป็นไปอย่างรวดเร็ว ต่อเนื่อง และมีความแม่นยำมากยิ่งขึ้น ทั้งยังช่วยลดภาระงานของเจ้าหน้าที่ตรวจสอบความปลอดภัย (Safety Officer) และยกระดับมาตรการด้านความปลอดภัยในโรงงานอุตสาหกรรมให้มีประสิทธิภาพมากยิ่งขึ้น

2. ปัญหาวิจัย (Research Problem)

ปัจจุบันการตรวจสอบการสวมใส่หมวกนิรภัยของพนักงานในโรงงานอุตสาหกรรมยังอาศัยการตรวจด้วยสายตาของเจ้าหน้าที่ ซึ่งมีข้อจำกัดด้านความถูกต้อง ความรวดเร็ว และความต่อเนื่อง ทำให้เกิดความเสี่ยงด้านความปลอดภัยต่อพนักงาน และเพิ่มภาระการทำงานของเจ้าหน้าที่ตรวจสอบ จึงเกิดคำถามว่า จะสามารถพัฒนาระบบตรวจจับการสวมหมวกนิรภัยแบบอัตโนมัติ โดยใช้เทคโนโลยีการประมวลผลภาพ (Computer Vision) เพื่อช่วยลดเวลา เพิ่มความถูกต้อง และเพิ่มประสิทธิภาพในการตรวจสอบได้อย่างไร

ปัจจุบันการตรวจสอบการสวมหมวกนิรภัยในโรงงานอุตสาหกรรมยังคงใช้แรงงานมนุษย์ซึ่งมีข้อจำกัดทั้งด้านเวลา และความถูกต้อง จึงเกิดคำถามว่า จะสามารถพัฒนาระบบตรวจจับการสวมหมวกนิรภัยแบบอัตโนมัติที่ทำงานได้อย่างรวดเร็ว และแม่นยำ เพื่อช่วยเพิ่มประสิทธิภาพและลดความผิดพลาดในการตรวจสอบได้หรือไม่

3. คำถามวิจัย (Research Questions)

- 3.1 จะสามารถพัฒนาระบบตรวจจับการสวมหมวกนิรภัยแบบอัตโนมัติ โดยใช้เทคโนโลยีการประมวลผลภาพ (Computer Vision) เพื่อช่วยเพิ่มความแม่นยำ ความรวดเร็ว และความต่อเนื่องในการตรวจสอบความปลอดภัยของพนักงานได้อย่างไร
- 3.2 จะสามารถพัฒนาระบบตรวจจับการสวมหมวกนิรภัยของพนักงานในโรงงานอุตสาหกรรมด้วยเทคโนโลยีการประมวลผลภาพได้หรือไม่
- 3.3 ระบบที่พัฒนา มีความแม่นยำและประสิทธิภาพในการตรวจจับมากน้อยเพียงใด
- 3.4 ระบบสามารถช่วยลดเวลาและเพิ่มความต่อเนื่องในการตรวจสอบความปลอดภัยได้หรือไม่

4. วัตถุประสงค์ของการวิจัย

เพื่อพัฒนาระบบตรวจจับการสวมใส่หมวกนิรภัยของพนักงานในสายการผลิต โดยใช้เทคโนโลยี Computer Vision แบบ Real-time

5. สมมติฐานการวิจัย

- 5.1 ระบบตรวจจับอัตโนมัติ ลดเวลาเฉลี่ยในการตรวจหนึ่งคน และ เพิ่มอัตราการตรวจต่อหน่วยเวลา เมื่อเทียบกับวิธีเดิมอย่างมีนัยสำคัญ
- 5.2 สภาพแสงและมุมกล้อง มีผลต่อประสิทธิภาพการตรวจจับอย่างมีนัยสำคัญ และมีปฏิสัมพันธ์กัน

6. รายละเอียดเกี่ยวกับองค์กร

บริษัทแห่งหนึ่งดำเนินธุรกิจด้านการผลิตชิ้นส่วนยานยนต์เพื่อส่งมอบให้กับผู้ประกอบการในอุตสาหกรรมยานยนต์รายใหญ่ ทั้งในประเทศและต่างประเทศ โดยมีลูกค้าหลักเป็นผู้ผลิตรถยนต์ชั้นนำ รวมถึงผู้ผลิตระบบและอุปกรณ์ประกอบภายในยานยนต์ นอกจากนี้ยังขยายการผลิตไปสู่ชิ้นส่วนเครื่องใช้ไฟฟ้า เพื่อจัดจำหน่ายให้กับผู้ประกอบการรายสำคัญที่เป็นแบรนด์ชั้นนำระดับโลก

7. มาตรฐานการบริหารจัดการ

บริษัทได้รับการรับรองระบบมาตรฐานสากลที่สำคัญ ได้แก่

1. ISO 9001 : ระบบบริหารคุณภาพ
2. IATF 16949 : ระบบมาตรฐานสำหรับอุตสาหกรรมยานยนต์
3. ISO 14001 : ระบบการจัดการสิ่งแวดล้อม

8. ขอบเขตการวิจัย

- 8.1 ระบบจะมุ่งเน้นการตรวจจับการมีหรือไม่มีหมวกนิรภัยบนศีรษะของพนักงานเท่านั้น
- 8.2 แยกแยะหมวกนิรภัยออกจากสิ่งอื่นที่มีลักษณะใกล้เคียง เช่น หมวกแก๊ป , หมวกบักเก็ต เป็นต้น
- 8.3 ระบบจะแจ้งเตือนในรูปแบบข้อความบนหน้าจอเมื่อพบการไม่สวมหมวกนิรภัย
- 8.4 การตรวจจับจะต้องหันหน้าเข้าหากกล้อง หรือ หน้าจอเพื่อทำการตรวจจับการสวมหมวก

9. ประโยชน์ที่คาดว่าจะได้รับ

9.1 เชิงวิชาการ (Academic Benefits)

งานวิจัยนี้ช่วยยกระดับความปลอดภัยในภาคอุตสาหกรรม โดยนำเทคโนโลยี Computer Vision และ Deep Learning มาประยุกต์ใช้จริง เราได้พัฒนาต่อยอดโมเดลตรวจจับวัตถุอัจฉริยะอย่าง YOLO ให้สามารถตรวจสอบการสวมใส่อุปกรณ์นิรภัยของพนักงานได้อย่างแม่นยำและทันทั่วทั้งในสภาพแวดล้อมการทำงานจริง ซึ่งถือเป็นการขยายขอบเขตการใช้เทคโนโลยีนี้ให้เกิดประโยชน์อย่างเป็นรูปธรรม

9.2 เชิงปฏิบัติ (Practical Benefits)

9.2.1 เพิ่มประสิทธิภาพการตรวจสอบความปลอดภัยในโรงงานอุตสาหกรรมระบบที่พัฒนาขึ้นช่วยให้สามารถตรวจจับการสวมหมวกนิรภัยของพนักงานได้อย่างรวดเร็ว ถูกต้อง และต่อเนื่องตลอดเวลาการทำงาน ลดปัญหาความล่าช้าและความผิดพลาดจากมนุษย์

9.2.2 ลดภาระงานของเจ้าหน้าที่ความปลอดภัย (Safety Officer) จากการตรวจด้วยสายตาที่ต้องใช้เวลานานและมีความเมื่อยล้า ระบบอัตโนมัติจะช่วยให้เจ้าหน้าที่สามารถมุ่งเน้นไปที่งานด้านการวิเคราะห์และป้องกันอุบัติเหตุเชิงลึกมากขึ้น

9.2.3 ลดความสูญเสียจากอุบัติเหตุและเพิ่มผลผลิต (Productivity) เมื่อพนักงานปฏิบัติตามมาตรการความปลอดภัยอย่างเคร่งครัด จะช่วยลดโอกาสการเกิดอุบัติเหตุ ลดการหยุดชะงักของสายการผลิต และเพิ่มประสิทธิภาพการทำงานโดยรวมของโรงงาน

10. แผนดำเนินงานและระยะเวลาปฏิบัติงาน

Timeline	สัปดาห์ที่ 1 (31 Aug - 6 Sep)	สัปดาห์ที่ 2 (7 - 13 Sep)	สัปดาห์ที่ 3 (14 - 20 Sep)	สัปดาห์ที่ 4 (21 - 27 Sep)	สัปดาห์ที่ 5 (28 Sep - 4 Oct)	สัปดาห์ที่ 6 (5 - 10 Oct)
Data Collection						
Model Training						
Model Evaluation						
ปรับปรุง แก้ไข						
deployment/demo						
จัดทำเล่มรูปเล่มรายงาน						

ตารางที่ 1 แผนดำเนินงานและระยะเวลาปฏิบัติงาน

11. อุปกรณ์และเครื่องมือที่ใช้ในการพัฒนา

11.1 ฮาร์ดแวร์ที่ใช้ในการพัฒนา

11.1.1 คอมพิวเตอร์ MacOS

- หน่วยประมวลผลกลาง Apple M4 CPU แบบ 10-core และ Apple M2 CPU แบบ 8-core
- หน่วยประมวลผลกราฟิก Apple GPU แบบ 8-core
- หน่วยประมวลผล Apple Neural Engine แบบ 16-core
- หน่วยความจำหลัก 120 GB/s และ 100 GB/s

11.1.2 คอมพิวเตอร์ Window

- หน่วยประมวลผลกลาง Intel(R) Core (TM) i5-11400U CPU @2.70GHz 4.50 GHz และ Intel(R) Core (TM) i7-1255U @1.70 GHz
- หน่วยประมวลผลกราฟิก NVIDIA GeForce RTX 3050 Laptop และ Intel(R) Iris(R) Xe Graphics (128 MB)
- หน่วยความจำหลักขนาดความจุ 16.0 GB

11.2 ซอฟต์แวร์ที่ใช้ในการพัฒนา

ระบบปฏิบัติการ macOS Tahoe 26.0.1 และ Windows 10 โปรแกรมที่ใช้ในการเขียนโปรแกรม Google Colab และ Vscode

บทที่ 2

เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีและแนวคิดที่เกี่ยวข้อง

2.1.1 คอนโวลูชันนัลนิวรัลเน็ตเวิร์ก (Convolutional Neural Network: CNN)

คอนโวลูชันนัลนิวรัลเน็ตเวิร์ก (Convolutional Neural Network: CNN) เป็นสถาปัตยกรรมของโครงข่ายประสาทเทียมเชิงลึก (Deep Neural Network) ที่ได้รับการออกแบบมาเพื่อประมวลผลข้อมูลเชิงพื้นที่ โดยเฉพาะข้อมูลภาพ (Image Data) ซึ่งมีลักษณะเป็นเมทริกซ์ของพิกเซลที่มีการจัดเรียงตามตำแหน่งและมีความสัมพันธ์กัน [1], [2] โครงสร้างพื้นฐานของ CNN ประกอบด้วยชั้นหลักๆ ได้แก่

1. Convolutional Layer (ชั้นคอนโวลูชัน)

เป็นชั้นที่สำคัญที่สุดในสถาปัตยกรรม CNN ทำหน้าที่สกัดคุณลักษณะ (Feature Extraction) ของภาพ โดยใช้ตัวกรองหรือเคอร์เนล (Kernel/Filter) ขนาดเล็กทำการคอนโวลูชัน (Convolution Operation) กับภาพต้นฉบับ เพื่อดึงลักษณะเฉพาะ เช่น ขอบ (Edge) , รูปร่าง (Shape) หรือพื้นผิว (Texture) ออกมา ซึ่งค่าในแต่ละชั้นจะเป็น Feature Map ที่แสดงความโดดเด่นของลักษณะต่าง ๆ ภายในภาพ

2. Pooling Layer (ชั้นย่อขนาดข้อมูล)

ทำหน้าที่ลดขนาดของ Feature Map เพื่อลดจำนวนพารามิเตอร์และเวลาการคำนวณ โดยไม่ทำให้ข้อมูลสำคัญสูญหาย เช่น Max Pooling และ Average Pooling ซึ่งช่วยให้โมเดลสามารถเรียนรู้คุณลักษณะได้อย่างมีประสิทธิภาพมากขึ้น [3]

3. Activation Function (ฟังก์ชันกระตุ้น)

ทำหน้าที่เพิ่มความไม่เชิงเส้น (Non-linearity) ให้กับโมเดล เพื่อให้สามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนได้ ตัวอย่างฟังก์ชันที่นิยมใช้ได้แก่ ReLU (Rectified Linear Unit) , Sigmoid และ Tanh โดยเฉพาะ ReLU ซึ่งช่วยลดปัญหา Gradient Vanishing และเพิ่มความเร็วในการเรียนรู้ [4]

4. Fully Connected Layer (ชั้นเชื่อมต่อเต็ม)

เป็นชั้นสุดท้ายของ CNN ที่เชื่อมต่อทุกโหนดจากชั้นก่อนหน้าเข้ากับโหนดของชั้นถัดไป เพื่อทำการจำแนกประเภท (Classification) หรือการคาดคะเนผลลัพธ์ (Prediction)

ในงานด้าน การประมวลผลภาพ (Image Processing) CNN ได้รับการพิสูจน์แล้วว่ามีความมีประสิทธิภาพสูงในการตรวจจับและจำแนกวัตถุ เช่น ในงานจำแนกภาพ (Image Classification) , การจดจำใบหน้า (Face Recognition) และการตรวจจับวัตถุ (Object Detection) ซึ่งเป็นพื้นฐานสำคัญในการพัฒนาระบบอัจฉริยะในอุตสาหกรรมสมัยใหม่ [5]

2.1.2 แนวคิดของโมเดล YOLO (You Only Look Once)

โมเดล YOLO (You Only Look Once) เป็นอัลกอริทึมสำหรับการตรวจจับวัตถุ (Object Detection) ที่พัฒนา [6] ซึ่งมีจุดเด่นคือ สามารถตรวจจับวัตถุได้แบบเรียลไทม์ (Real-time Detection) ด้วยความเร็วและความแม่นยำสูงกว่าเทคนิคการตรวจจับแบบดั้งเดิม เช่น R-CNN หรือ Faster R-CNN

หลักการทำงานของ YOLO คือ การมองภาพเพียงครั้งเดียว (“You Only Look Once”) แล้วแบ่งภาพออกเป็นตาราง (Grid Cells) แต่ละเซลล์จะทำนาย Bounding Box และค่าความน่าจะเป็น (Confidence Score) ของวัตถุที่อยู่ภายในเซลล์นั้น ๆ พร้อมทั้งระบุประเภทของวัตถุ (Class Label) จากนั้นโมเดลจะรวมผลลัพธ์ทั้งหมดเพื่อสร้างการตรวจจับที่แม่นยำและรวดเร็ว

โมเดล YOLO ได้รับการพัฒนาและปรับปรุงต่อเนื่องหลายรุ่น ได้แก่

1. YOLOv1 (2016) คือ รุ่นแรกที่เสนอแนวคิดมองภาพเพียงครั้งเดียว ทำให้ตรวจจับวัตถุได้เร็วกว่าเทคนิคก่อนหน้านี้ [6]
2. YOLOv2 (YOLO9000) คือ เพิ่มความละเอียดของภาพและใช้ Batch Normalization ทำให้ความแม่นยำสูงขึ้น [7]
3. YOLOv3 คือ ปรับโครงสร้าง Backbone เป็น Darknet-53 และสามารถตรวจจับวัตถุหลายขนาดในภาพเดียวได้ [8]
4. YOLOv4 คือ เพิ่มเทคนิค CSPDarknet และใช้ Mosaic Data Augmentation เพื่อเพิ่มความหลากหลายของข้อมูลและลด Overfitting [9]
5. YOLOv5 คือ พัฒนาโดย Ultralytics ให้มีความยืดหยุ่นมากขึ้น สามารถปรับแต่งขนาดโมเดล (S, M, L, X) และรองรับการฝึกโมเดลบน GPU ได้ง่าย
6. YOLOv8 คือ รุ่นล่าสุดที่ปรับโครงสร้างสถาปัตยกรรมให้มีความเสถียรและมีความแม่นยำสูงขึ้น รองรับการทำงานและจำแนกภาพได้ในโมเดลเดียว

คุณสมบัติสำคัญของ YOLO ได้แก่

1. ความเร็วสูง (High Speed): สามารถประมวลผลภาพได้หลายสิบภาพต่อวินาที (FPS) เหมาะสำหรับการใช้งานแบบเรียลไทม์ เช่น ระบบตรวจจับความปลอดภัยในโรงงาน
2. ประสิทธิภาพสูง (High Accuracy): มีค่าความแม่นยำเฉลี่ย (Mean Average Precision: mAP) สูง โดยเฉพาะใน YOLOv5 และ YOLOv8 ที่ได้รับการปรับปรุงโครงสร้างให้แม่นยำกว่าเดิม
3. ใช้งานง่าย (Ease of Deployment): รองรับการใช้งานบนอุปกรณ์หลากหลายประเภท เช่น กล้องวงจรปิด หรือระบบฝังตัว (Embedded Systems)

สำหรับงานวิจัยนี้ โมเดล YOLO ถูกนำมาใช้ในการพัฒนา ระบบตรวจจับการสวมหมวกนิรภัยแบบเรียลไทม์ เพื่อให้สามารถระบุและจำแนกผู้ที่ “สวมหมวก” และ “ไม่สวมหมวก” หมวกนิรภัยได้อย่างแม่นยำภายในภาพเดียว ช่วยลดความผิดพลาดจากการตรวจสอบด้วยมนุษย์และเพิ่มประสิทธิภาพในการบริหารจัดการความปลอดภัยภายในโรงงานอุตสาหกรรม

2.1.3 ทฤษฎีของการมองเห็นของคอมพิวเตอร์ (Computer Vision Theory)

การมองเห็นของคอมพิวเตอร์ (Computer Vision) เป็นศาสตร์ที่เกี่ยวข้องกับการทำให้เครื่องคอมพิวเตอร์สามารถมองเห็น และ ตีความ ของภาพได้ในลักษณะคล้ายมนุษย์ โดยอาศัยหลักการทางคณิตศาสตร์ สถิติ และปัญญาประดิษฐ์ เพื่อให้คอมพิวเตอร์สามารถสกัดข้อมูลเชิงความหมาย (Semantic Information) จากข้อมูลภาพดิจิทัล (Digital Images) หรือวิดีโอ (Video Sequences) ได้อย่างถูกต้องและแม่นยำ [10]

ทฤษฎีพื้นฐานของการมองเห็นของคอมพิวเตอร์มีจุดกำเนิดมาจากแนวคิดของการมองเห็นในมนุษย์ (Human Vision) ซึ่งอธิบายกระบวนการรับภาพของดวงตาและสมองมนุษย์ โดยแปลงพลังงานแสงเป็นสัญญาณประสาท และประมวลผลเพื่อสร้างการรับรู้เชิงภาพ (Visual Perception) แนวคิดนี้ได้ถูกนำมาประยุกต์ใช้ในทางคอมพิวเตอร์เพื่อพัฒนาแบบจำลองทางคณิตศาสตร์ที่สามารถจำลองกระบวนการดังกล่าว [11]

ได้เสนอ [11] “ทฤษฎีการมองเห็นสามระดับ” (Three Levels of Visual Processing) ได้แก่

1. ระดับการคำนวณ (Computational Level): อธิบายว่าระบบการมองเห็นต้องทำอะไร เช่น การสกัดขอบ (Edge Detection) หรือการแยกวัตถุจากพื้นหลัง
2. ระดับอัลกอริทึม (Algorithmic Level): อธิบายว่าขั้นตอนหรือกระบวนการใดที่ใช้ในการแก้ปัญหาด้านการมองเห็น เช่น การคำนวณคุณลักษณะของภาพ (Feature Extraction)
3. ระดับการนำไปใช้จริง (Implementation Level): ว่าจะนำอัลกอริทึมเหล่านั้นไปประมวลผลอย่างไรในระบบคอมพิวเตอร์จริง

ในทางทฤษฎี การมองเห็นของคอมพิวเตอร์ประกอบด้วย สองกระบวนการหลัก ได้แก่

1. การประมวลผลภาพ (Image Processing): เป็นขั้นตอนเบื้องต้นในการปรับปรุงคุณภาพของภาพ เช่น การกรองสัญญาณรบกวน (Noise Filtering) การเพิ่มความคมชัด (Enhancement) และการตรวจจับขอบ (Edge Detection) เพื่อเตรียมข้อมูลให้พร้อมสำหรับการวิเคราะห์ขั้นต่อไป
2. การเข้าใจภาพ (Image Understanding): เป็นขั้นตอนที่ระบบจะตีความภาพและระบุวัตถุในภาพ เช่น การจำแนกประเภท (Classification) การตรวจจับ (Detection) หรือการติดตามการเคลื่อนไหว (Tracking) โดยใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) และการเรียนรู้เชิงลึก (Deep Learning)

ภายใต้ทฤษฎีของการมองเห็นของคอมพิวเตอร์ แนวคิดเรื่อง “การแทนภาพเชิงลำดับชั้น” (Hierarchical Representation of Vision) ถือเป็นรากฐานสำคัญของเทคนิคสมัยใหม่ เช่น โครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) ซึ่งอาศัยหลักการเดียวกับการมองเห็นของสมองมนุษย์ โดยให้ชั้นลึก ๆ ของโครงข่ายสามารถเรียนรู้ลักษณะเชิงนามธรรมของภาพจากลักษณะพื้นฐาน [1], [12]

2.2 ตัวชี้วัดการประเมินประสิทธิภาพ (Evaluation Metrics)

การเลือกตัวชี้วัด (Metric) ที่เหมาะสมขึ้นอยู่กับลักษณะของปัญหาและข้อมูลที่ใช้ในการฝึกโมเดล โดยตัวชี้วัดที่นิยมใช้ในการประเมินโมเดลด้านการจำแนกภาพและการตรวจจับวัตถุ ได้แก่

2.2.1 Precision (ความเที่ยงตรง)

ใช้วัดความถูกต้องของการทำนายค่าบวก หรือความสามารถของโมเดลในการลดการแจ้งเตือนผิดพลาด [13]

$$Precision = \frac{TP}{TP + FP}$$

ภาพที่ 1 สูตร Precision

2.2.2 Recall (ความไวในการตรวจจับ)

เป็นการวัดความสามารถของโมเดลในการตรวจจับข้อมูลที่เป็นบวกทั้งหมด

$$Recall = \frac{TP}{TP + FN}$$

ภาพที่ 2 สูตร Recall

2.2.3 Mean Average Precision (mAP)

เป็นตัวชี้วัดหลักที่ใช้ในการประเมินประสิทธิภาพของโมเดลตรวจจับวัตถุ เช่น YOLO, SSD หรือ Faster R-CNN โดยคำนวณจากค่าเฉลี่ยของค่า Average Precision (AP) ในแต่ละคลาส [14] ซึ่งสะท้อนความสามารถของโมเดลในการตรวจจับและจำแนกวัตถุได้อย่างถูกต้องทั้งในด้านตำแหน่งและประเภท

$$mAP_{model} = \frac{1}{n} \sum_{k=1}^{k=n} mAP_k$$

ภาพที่ 3 สูตร mAP

2.2.4 Confusion Matrix

เป็นตารางที่ใช้แสดงผลลัพธ์การทำนาย โดยแบ่งออกเป็นจำนวนข้อมูลที่ทำนายถูกและผิดในแต่ละคลาส เพื่อช่วยให้ผู้วิจัยเห็นจุดบกพร่องของโมเดลได้ชัดเจน [15]

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

ภาพที่ 4 Confusion Matrix

2.2.5 การประยุกต์ใช้ในงานตรวจจับการสวมหมวกนิรภัย

สำหรับงานวิจัยด้าน การตรวจจับการสวมหมวกนิรภัย (Helmet Detection) การประเมินประสิทธิภาพของโมเดลเป็นส่วนสำคัญที่ช่วยยืนยันความถูกต้องและความน่าเชื่อถือของระบบ โดยเฉพาะเมื่อใช้โมเดลประเภท CNN หรือ YOLO ซึ่งเน้นการระบุตำแหน่งและการจำแนกวัตถุในภาพแบบเรียลไทม์ ตัวชี้วัดที่นิยมใช้ ได้แก่ Precision, Recall, และ mAP เพื่อวัดประสิทธิภาพในการตรวจจับผู้ที่สวมและไม่สวมหมวกนิรภัย [16] นอกจากนี้ การใช้ Confusion Matrix ยังช่วยให้ผู้วิจัยสามารถระบุประเภทของความผิดพลาดที่เกิดขึ้น และปรับปรุงโมเดลให้มีความแม่นยำยิ่งขึ้นได้

2.3 แนวคิดเกี่ยวกับมาตรฐานสากล (International Standards)

2.3.1 มาตรฐาน ISO 45001 และกรอบการจัดการด้านอาชีวอนามัยและความปลอดภัย

ISO 45001:2018 เป็นมาตรฐานสากลสำหรับระบบการจัดการอาชีวอนามัยและความปลอดภัย (OH&S) เพื่อให้องค์กรทุกขนาดนำไปใช้ในการระบุอันตราย ประเมินความเสี่ยง กำหนดการควบคุม และปรับปรุงสมรรถนะด้านความปลอดภัยและสุขภาพของผู้ปฏิบัติงานอย่างต่อเนื่อง มาตรฐานฉบับนี้เผยแพร่เมื่อวันที่ 12 มีนาคม 2018 และเข้ามา “แทนที่” OHSAS 18001 โดยกำหนดช่วงเวลาเปลี่ยนผ่าน 3 ปีสำหรับองค์กรที่ได้รับรองเดิมให้ย้ายมาสู่ ISO 45001 ภายในเดือนมีนาคม 2021 ซึ่งเป็นการยกระดับให้สอดคล้องกับแนวคิดความเสี่ยง และการบูรณาการกับมาตรฐานระบบบริหารอื่นตาม Annex SL (เช่น ISO 9001, ISO 14001) ISO+1

โครงสร้างของมาตรฐานยึดตามวงจร PDCA (Plan-Do-Check-Act) โดยมี “ภาวะผู้นำและการมีส่วนร่วมของแรงงาน” เป็นแกนกลาง: Plan (ข้อ 6 การวางแผน), Do (ข้อ 7 การสนับสนุน และข้อ 8 การปฏิบัติการ), Check (ข้อ 9 การประเมินสมรรถนะ), และ Act (ข้อ 10 การปรับปรุง) แนวทาง PDCA นี้เป็นหัวใจของการปรับปรุงอย่างต่อเนื่องตามที่อธิบายไว้โดย ANSI ซึ่งสอดคล้องกับเจตนารมณ์ของ ISO 45001 ในการป้องกันการบาดเจ็บและเจ็บป่วยจากการทำงาน พร้อมทั้งส่งเสริมสุขภาพกายใจของผู้ปฏิบัติงาน

1. **Scope (ขอบเขต)** – ระบุขอบเขตการใช้มาตรฐานเพื่อบริหารจัดการอาชีวอนามัยและความปลอดภัย ให้สอดคล้องกฎหมายและวัตถุประสงค์องค์กร
2. **Normative Reference (เอกสารอ้างอิง)** – ไม่มีเอกสารอ้างอิง มาตรฐานฉบับนี้เป็นฉบับแรก
3. **Terms and Definitions (คำศัพท์และคำนิยาม)** – กำหนดไว้ 37 คำ ใช้ความหมายตามที่มาตรฐานนิยามไว้ และควรจัดทำเอกสารอ้างอิงภายในองค์กร
4. **Context of the Organization (บริบทองค์กร)** – สำรวจประเด็นภายใน/ภายนอก, ความต้องการผู้มีส่วนได้ส่วนเสีย, ขอบเขตระบบ, แนวทางการจัดทำระบบ
5. **Leadership and Worker Participation (ผู้นำและการมีส่วนร่วม)** – ผู้นำต้องแสดงความมุ่งมั่น, กำหนดนโยบาย, บทบาทหน้าที่ และเปิดโอกาสให้พนักงานมีส่วนร่วม
6. **Planning (การวางแผน)** – วางแผนจัดการความเสี่ยงและโอกาส, กำหนดวัตถุประสงค์ เป้าหมาย และแผนดำเนินงาน
7. **Support (การสนับสนุน)** – จัดสรรทรัพยากร, พัฒนาความรู้และจิตสำนึก, ระบบสื่อสาร, และควบคุมเอกสารสารสนเทศ
8. **Operation (การปฏิบัติงาน)** – ควบคุมการดำเนินงานตามความเสี่ยงและโอกาส, จัดการเหตุฉุกเฉินและฝึกซ้อมรับมือ
9. **Performance Evaluation (การประเมินสมรรถนะ)** – ติดตามและประเมินผล, ตรวจสอบติดตามภายใน, ประชุมทบทวนโดยผู้บริหาร
10. **Improvement (การปรับปรุง)** – ปรับปรุงผลลัพธ์ระบบ, แก้ไขข้อบกพร่อง/อุบัติเหตุ, และพัฒนาอย่างต่อเนื่องให้เหมาะสมกับองค์กร

2.3.2 การประยุกต์ใช้วิสัยทัศน์คอมพิวเตอร์กับความปลอดภัย: การตรวจจับการสวมหมวกนิรภัย

เพื่อตอบโจทย์ข้อกำหนดด้านการควบคุมความเสี่ยงตาม ISO 45001 หลายงานวิจัยได้ใช้เทคนิควิสัยทัศน์คอมพิวเตอร์ (Computer Vision) และโครงข่ายประสาทเทียมเชิงลึก (Deep Learning) พัฒนาระบบตรวจจับ “การสวม/ไม่สวมหมวกนิรภัย” ทั้งในโรงงานและบนท้องถนน โดยชุดวิธีตระกูล YOLO (You Only Look Once) ได้รับความนิยมเนื่องจากความเร็วสูงและเหมาะกับการทำงานแบบ Real-time ตัวอย่างเช่น งานของ Shoman และคณะบูรณาการ YOLOv8 กับภาพที่สร้างด้วย DCGAN เพื่อเพิ่มความแม่นยำในการตรวจจับการฝ่าฝืนการสวมหมวกของผู้ขับขี่รถจักรยานยนต์ในโลกจริง

2.4 การทบทวนวรรณกรรม

2.4.1 งานของ Zhang และคณะ (2025)

มีวัตถุประสงค์หลักในการพัฒนาและปรับปรุงแบบจำลอง YOLOv8 สำหรับการตรวจจับหมวกนิรภัยในสภาพแวดล้อมอุตสาหกรรม [16] โดยมุ่งเน้นให้โมเดลมีความเบา (lightweight) และสามารถทำงานได้อย่างมีประสิทธิภาพในระบบที่มีทรัพยากรจำกัด เช่น อุปกรณ์ฝังตัวและกล้องเฝ้าระวังแบบ Real-time

งานวิจัยดังกล่าวได้เสนอโมเดลชื่อว่า FGP-YOLOv8 ซึ่งเป็นการปรับปรุง YOLOv8 โดยใช้เทคนิคดังต่อไปนี้

1. เปลี่ยนโครงสร้าง Backbone จาก C2f เป็น FasterNet เพื่อเพิ่มความเร็วและลดจำนวนพารามิเตอร์ของโมเดล
2. เพิ่มโมดูล GSTA (GSConv-Triplet Attention) เพื่อเสริมประสิทธิภาพในการดึงคุณลักษณะ (Feature Extraction) ให้เหมาะกับวัตถุขนาดเล็กและสภาพแวดล้อมซับซ้อน
3. ปรับฟังก์ชันสูญเสีย (Loss Function) ให้เป็น WIoU (Weighted IoU) เพื่อเพิ่มความแม่นยำของการระบุตำแหน่งวัตถุ
4. ใช้เทคนิค Mosaic Data Augmentation เพื่อเพิ่มความหลากหลายของข้อมูลและเพิ่มความสามารถของโมเดลในการตรวจจับในสภาพแสงที่แตกต่างกัน

ผลการทดลองแสดงให้เห็นว่าโมเดล FGP-YOLOv8 ที่พัฒนาขึ้นสามารถเพิ่มค่า mAP@0.5 ได้ถึง 2.3% และลดภาระการคำนวณลงกว่า 18.5% เมื่อเทียบกับ YOLOv8n ดั้งเดิม ทั้งนี้ยังสามารถรักษาความเร็วในการประมวลผล (FPS) ให้อยู่ในระดับที่เหมาะสมต่อการใช้งานแบบ Real-time ซึ่งแสดงให้เห็นถึงศักยภาพของโมเดลเชิงลึกแบบเบาในการประยุกต์ใช้กับงานตรวจจับหมวกนิรภัยในอุตสาหกรรมจริง

2.4.2 งานของ Deng (2024)

มีวัตถุประสงค์เพื่อพัฒนาโมเดลตรวจจับการสวมหมวกนิรภัยของผู้ขับขี่จักรยานหรือรถจักรยานยนต์อย่างมีประสิทธิภาพมากขึ้น [12] ทั้งในด้านความแม่นยำและความเร็ว เพื่อสนับสนุนความปลอดภัยบนท้องถนนและลดอุบัติเหตุที่เกิดจากการไม่สวมหมวกนิรภัย ผู้วิจัยเลือกใช้โมเดล YOLOv8n ซึ่งเป็นรุ่นย่อยของ YOLOv8 ที่มีขนาดเล็กและทำงานได้รวดเร็ว มาเป็นโมเดลพื้นฐาน จากนั้นได้ปรับปรุงโครงสร้างเพื่อเพิ่มประสิทธิภาพ โดยเพิ่มโมดูล Squeeze-and-Excitation Network (SENet) เพื่อช่วยให้โมเดลเน้นการเรียนรู้บริเวณที่สำคัญในภาพ แทนที่บางส่วนของ convolution ด้วย Lightweight Convolution (LConv) เพื่อเพิ่มความเร็วและลดภาระการคำนวณ เปลี่ยนฟังก์ชันสูญเสียเป็น Wise-IoU (WIoU) เพื่อเพิ่มความแม่นยำของกรอบตรวจจับ และเพิ่มขั้นตอนอนุมานด้วยเทคนิค Slicing Aided Hyper Inference (SAHI) เพื่อช่วยให้ตรวจจับวัตถุขนาดเล็กได้ดียิ่งขึ้น

บทที่ 3

วิธีดำเนินการวิจัย

การวิจัยครั้งนี้มีวัตถุประสงค์เพื่อพัฒนาระบบตรวจจับการใส่หมวกนิรภัยในโรงงานอุตสาหกรรม โดยใช้เทคนิคการประมวลผลภาพ (Image Processing) และการเรียนรู้เชิงลึก (Deep Learning) เพื่อสร้างแบบจำลองที่สามารถตรวจจับและจำแนกการสวมหมวกนิรภัยได้อย่างแม่นยำในสภาพแวดล้อมจริง คณะผู้วิจัยได้ดำเนินการศึกษาตามขั้นตอนดังต่อไปนี้

3.1 รูปแบบการวิจัย (Research Design)

งานวิจัยนี้เป็นการวิจัยเชิงประยุกต์ (Applied Research) ที่มีลักษณะเป็นการวิจัยเชิงทดลอง (Experimental Research) โดยมุ่งพัฒนาและทดสอบระบบตรวจจับการใส่หมวกนิรภัยในสภาพแวดล้อมจำลองที่ใกล้เคียงโรงงานจริง เพื่อให้สามารถตรวจสอบการปฏิบัติตามกฎความปลอดภัยของพนักงานได้อย่างแม่นยำและเชื่อมโยงตัวตนผู้ใช้งานโดยระบบถูกออกแบบให้พร้อมนำไปใช้งานจริงในบริบทความปลอดภัยอุตสาหกรรม

3.2 ประชากรและกลุ่มตัวอย่าง (Population and Sample)

3.2.1 ประชากร (Population)

ประชากรของโครงการนี้ คือ ภาพของพนักงานในโรงงานอุตสาหกรรมที่ต้องปฏิบัติตามกฎระเบียบด้านความปลอดภัยในการสวมหมวกนิรภัยระหว่างปฏิบัติงาน

3.2.2 กลุ่มตัวอย่าง (Sample)

กลุ่มตัวอย่างของโครงการนี้คือ ชุดข้อมูลภาพจากสาธารณะที่คัดเลือกมาเพื่อฝึกและประเมินโมเดล ดังนี้

รายการ	รายละเอียด
แหล่งข้อมูล (Source)	Kaggle – Helmet Detection Dataset Pinterest – Non-Safety Helmets & Hats
จำนวนภาพทั้งหมด	23,673 ภาพ (Kaggle) 1,700 ภาพ (Pinterest)
ขนาดภาพ (Resolution)	640 × 640 pixels
ประเภทข้อมูล (Classification)	- ใส่หมวกนิรภัย (Helmet = 1) - ไม่ใส่หมวกนิรภัย (No Helme = 0)
รูปแบบป้ายกำกับ	YOLO format (Bounding Box: class, x_center, y_center, width, height)
จุดเด่นของข้อมูล	ครอบคลุมทั้งผู้ที่สวมหมวกนิรภัย และไม่สวมหมวกนิรภัย, การทำป้ายกำกับข้อมูล (Labeling) เติร์มไว้แล้ว

รายการ	รายละเอียด
การใช้เสริม (Benchmark)	ใช้ pre-training / transfer learning
แนวทางเก็บเพิ่ม	เพิ่มความหลากหลายของสภาพแสง/มุมมอง, Data Augmentation

ตารางที่ 2 กลุ่มตัวอย่าง

3.3 การเก็บ และ เตรียมข้อมูล (Data Collection and Pre-processing)

3.3.1 แหล่งข้อมูล

1. Kaggle Helmet Detection Dataset ภาพบุคคลที่สวมหมวกนิรภัยในบริบทการทำงาน ใช้สำหรับสร้างตัวอย่างคลาส Helmet และ No Helmet (กรณีสวมไม่ถูกต้อง/ไม่สวม)
2. Pinterest ภาพบุคคลที่สวมใส่หมวกชนิดอื่นๆ (Non-Safety Helmets & Hats)

3.3.2 เกณฑ์คัดเลือกภาพ

1. ความคมชัดเพียงพอ เห็นศีรษะ/หมวกชัดเจน
2. ความหลากหลายของมุม, แสง, ระยะ
3. การกระจายตัวอย่างสมดุลระหว่าง “สวมหมวกนิรภัย” และ “ไม่สวมหมวกนิรภัย”
4. มีภาพใบหน้าพนักงานที่ครอบคลุมองศาใบหน้า: หน้าตรง 0°, ด้านซ้าย 45°, ด้านขวา 45°
5. คัดเฉพาะภาพที่มีบุคคลซึ่งอยู่ในสองกรณีเป้าหมาย (Helmet / No Helmet)

3.3.3 นิยามคลาสข้อมูล (Class Definitions)

1. Helmet บุคคลที่สวมหมวกนิรภัยตามระเบียบความปลอดภัย
2. No Helmet บุคคลที่ไม่สวมหมวกนิรภัยหรือสวมไม่ถูกต้องจนมองไม่เป็นการสวม

3.4 การเตรียมข้อมูล (Pre-processing)

3.4.1 Annotation

1. ทำการระบุกรอบสี่เหลี่ยม (Bounding Box) รอบหมวกนิรภัยและศีรษะของพนักงาน
2. บันทึกตำแหน่งและประเภทของวัตถุเป็น “Helmet” และ “No Helmet” เพื่อสร้าง Ground Truth

3.4.2 การปรับแต่งภาพ (Image Adjustment)

1. ปรับขนาดภาพให้อยู่ในมาตรฐานที่โมเดลรองรับ (เช่น 416×416 หรือ 640×640 พิกเซล)
2. ทำ Normalize ค่า Pixel ให้อยู่ในช่วง 0–1

3.4.3 Data Augmentation

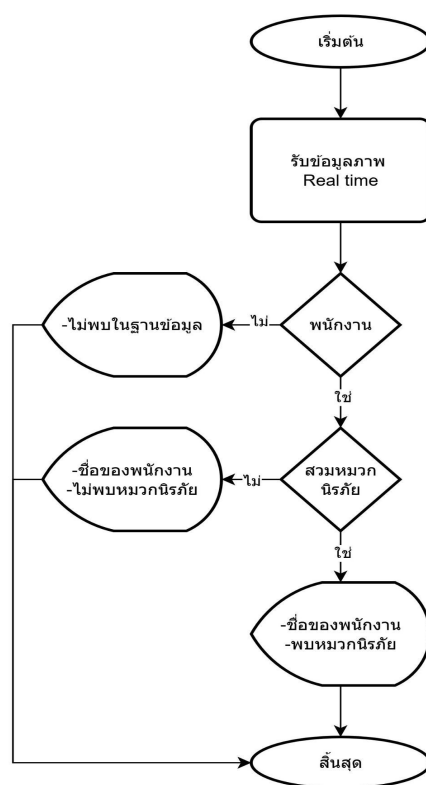
1. พลิกภาพ (Flip) ซ้าย-ขวา
2. หมุนภาพ (Rotation)
3. ปรับแสงและความสว่าง (Brightness Adjustment)

เพิ่มภาพด้วยเทคนิค Mosaic เพื่อให้โมเดลเห็นวัตถุขนาดเล็กหลายตำแหน่งในภาพเดียว ขั้นตอนนี้ช่วยเพิ่มจำนวนข้อมูล ลด Overfitting และเพิ่มความทนทานของโมเดล

3.4.4 การแบ่งชุดข้อมูล (Dataset Splitting)

1. Training set 70%
2. Validation set 15%
3. Test set 15%

3.5 แผนภาพกระบวนการวิจัย (Workflow Diagram)



ภาพที่ 5 แผนภาพกระบวนการวิจัย

แผนภาพกระบวนการวิจัย ดังภาพที่ 5 แสดงลำดับการทำงานของระบบตรวจจับการสวมหมวกนิรภัยแบบ Real-time โดยใช้เทคโนโลยีคอมพิวเตอร์วิทัศน์ (Computer Vision) เพื่อสนับสนุนการตรวจสอบความปลอดภัยของพนักงานในสายการผลิตอย่างต่อเนื่องและแม่นยำ ระบบเริ่มจากการรับข้อมูลภาพแบบ Real-time แล้วส่งเข้าสู่กระบวนการตรวจจับวัตถุ (Object Detection) เพื่อพิจารณาว่าเป็น พนักงานหรือไม่ หากไม่ใช่พนักงาน ระบบจะแสดงว่า ไม่พบในฐานข้อมูลแต่หากตรวจพบว่าเป็นพนักงาน ระบบจะดำเนินการตรวจสอบต่อว่า สวมหมวกนิรภัย หรือไม่ หากไม่สวมหมวกนิรภัย ระบบจะบันทึกข้อมูลและรายงานผลว่า ชื่อพนักงานไม่พบหมวกนิรภัย และในกรณีที่สวม ระบบจะบันทึกผลว่า ชื่อพนักงาน พบหมวกนิรภัย โดยกระบวนการทั้งหมดทำงานแบบวนซ้ำอย่างต่อเนื่อง เพื่อให้สามารถตรวจจับสถานะการสวมหมวกนิรภัยของพนักงานได้แบบ Real-time

3.6 การสร้างเครื่องมือในการวิจัย (Research Instruments)

3.6.1 แบบจำลองที่ใช้ในการตรวจจับวัตถุ

แบบจำลองที่ใช้คือ YOLO (You Only Look Once) ซึ่งเป็นอัลกอริทึมกลุ่ม One-Stage Detector จุดเด่นของ YOLO คือการตรวจจับและจำแนกวัตถุได้ในขั้นตอนเดียว จึงมีความเร็วสูง เหมาะกับการประมวลผลแบบ Real-time ซึ่งตอบโจทย์งานด้านความปลอดภัยในโรงงาน

3.6.2 การปรับปรุงและฝึกโมเดล (Transfer Learning and Fine-tuning)

1. ใช้ Pre-trained YOLO Model ที่ผ่านการฝึกบนชุดข้อมูลมาตรฐาน (COCO Dataset)
2. ปรับ Output Layer ให้จำแนกเพียง 2 คลาส คือ “Helmet” และ “No Helmet”
3. ทำ Fine-tuning กับชุดข้อมูลหมวกนิรภัยของโรงงาน เพื่อให้โมเดลเรียนรู้ลักษณะเฉพาะของหมวกและใบหน้าในสภาพจริง
4. กำหนดจำนวนรอบการฝึก (Epoch) ประมาณ 30–70 รอบ ขึ้นอยู่กับผลการประเมินความแม่นยำ

3.6.3 ทรัพยากรที่ใช้ในการพัฒนา

1. Hardware: GPU รุ่น A100 GPU (Google Colab)
2. Software: Python, Visual Studio Code (VS Code), Google Chrome, Microsoft Edge
3. Framework: YOLO Framework (PyTorch-based)

3.7 การประเมินผล (Model Evaluation)

3.7.1 Precision

ใช้วัดความถูกต้องของการทำนายค่าบวก หรือความสามารถของโมเดลในการ ลดการแจ้งเตือนผิดพลาด

3.7.2 Recall

เป็นการวัดความสามารถของโมเดลในการตรวจจับข้อมูลที่เป็นบวกทั้งหมด

3.7.3 Mean Average Precision (mAP)

เป็นตัวชี้วัดหลักที่ใช้ในการประเมินประสิทธิภาพของโมเดลตรวจจับวัตถุ เช่น YOLO หรือ CNN โดยคำนวณจากค่าเฉลี่ยของค่า Average Precision (AP) ในแต่ละคลาส ซึ่งสะท้อนความสามารถของโมเดลในการตรวจจับและจำแนกวัตถุได้อย่างถูกต้องทั้งในด้านตำแหน่งและประเภท

3.7.4 Confusion Matrix

เป็นตารางที่ใช้แสดงผลลัพธ์การทำนาย โดยแบ่งออกเป็นจำนวนข้อมูลที่ทำนายถูกและผิดในแต่ละคลาส เพื่อช่วยให้ผู้วิจัยเห็นจุดบกพร่องของโมเดลได้ชัดเจน

3.8 ขั้นตอนการประเมินผล

1. ทำการทดสอบโมเดลบน Test Set ที่ไม่เคยใช้ฝึกมาก่อน
2. เพิ่มเติมในสภาพแวดล้อมจริง (โรงงานจริง) เพื่อตรวจสอบความแม่นยำและความเร็วของระบบภายใต้แสง มุมกล้อง และระยะที่แตกต่างกัน

บทที่ 4


ผลการดำเนินงาน

4.1 ความหมายของตัวแปร

ชื่อตัวแปร	ความหมาย
epochs = 20	20 รอบเพียงพอสำหรับ dataset ขนาดกลางที่ fine-tune จาก pretrained model อยู่แล้ว ถ้ามากเกินไปจะทำให้โมเดลเรียนรู้รายละเอียดบนชุดข้อมูลฝึกมากเกินไป (overfitting) และเปลืองเวลา โดยผลลัพธ์ไม่ได้เพิ่มมากนัก
imgsz = 640	640 เป็นขนาดที่ YOLOv8 ใช้เป็นมาตรฐาน (trade-off ดีสุดระหว่าง resolution กับ speed) ถ้าใช้ 1280 จะชัดขึ้นแต่ช้ากว่า 2-3 เท่า
batch = 32	เพื่อให้โมเดลสามารถประมวลผลภาพได้เร็วขึ้นต่อ epoch โดยไม่ใช่หน่วยความจำมากเกินไป และยังคงรักษาความเสถียรของการเรียนรู้ไว้ได้
lr0 = 0.001	0.001 คือค่า “ปลอดภัย” สำหรับ fine-tuning ค่าพอที่จะไม่ overshoot loss curve และเร็วพอให้ loss ลดลงเรื่อยๆ ภายใน ~20 epoch
pretrained = True	เพราะมี dataset ไม่ใหญ่มาก ใช้ pretrain จาก COCO dataset จะช่วยให้ model เข้าใจ feature พื้นฐาน (คน, หัว, หมวก ฯลฯ) แล้ว fine-tune เฉพาะ class ที่กำหนดไว้ (helmet / no-helmet)
seed = 12345	เพื่อให้กระบวนการฝึกโมเดลสามารถให้ผลลัพธ์ที่ ทำซ้ำได้ (Reproducible Results) ทุกครั้งที่ดำเนินการเทรน ซึ่งเป็นการควบคุมการสุ่มของกระบวนการต่างๆ


ตารางที่ 3 ความหมายของตัวแปร

4.2 ผลการฝึกฝนโมเดล



ภาพที่ 6 Train Losses

จากกราฟ Train losses นี้แสดงให้เห็นถึง แนวโน้มการลดลงอย่างสม่ำเสมอ ของค่า Loss ทั้งสามค่า ตลอดระยะเวลาการฝึกฝน 20 Epochs ซึ่งบ่งบอกว่าโมเดลเรียนรู้ได้อย่างมีประสิทธิภาพ โดย cls_loss เส้นสีส้ม มีการลดลงที่รวดเร็วและมากที่สุด ขณะที่ box_loss เส้นสีน้ำเงิน และ dfl_loss เส้นสีเขียว ก็ลดลงอย่างต่อเนื่องเช่นกัน ซึ่งลดลงไปอยู่ที่ประมาณ 1.1 และ 1.08 ตามลำดับ ในส่วนของ Epoch สุดท้าย จะบ่งบอกว่าโมเดลสามารถเรียนรู้การระบุตำแหน่งวัตถุ การจำแนกประเภทได้ดียิ่งขึ้นเรื่อย ๆ ตลอดการฝึกฝน

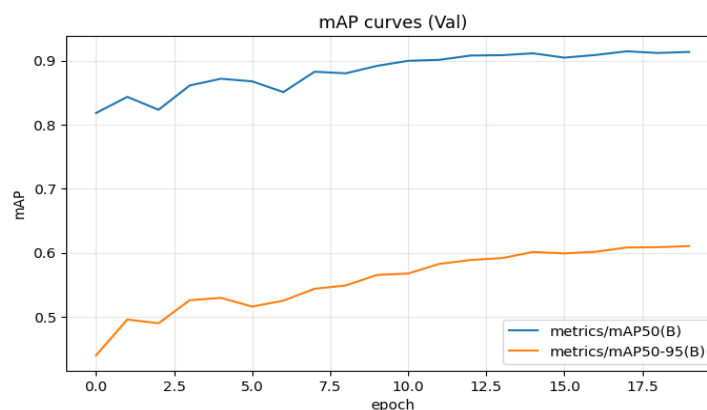


ภาพที่ 7 Valodation Losses

จากกราฟ Validation Losses นี้แสดงให้เห็นว่าโมเดลไม่ได้เกิด Overfitting อย่างชัดเจน เนื่องจากค่า loss ทั้งสามบนชุดข้อมูล Validation set ก็ ลดลงอย่างต่อเนื่อง ตลอด 20 Epochs โดยเฉพาะ cls_loss เส้นสีส้ม ที่ลดลงมากที่สุดจากประมาณ 1.2 เหลือเพียง 0.67 ในขณะที่ box_loss เส้นสีน้ำเงิน และ dfl_loss เส้นสีเขียว ก็ลดลงอย่างสม่ำเสมอไปอยู่ที่ประมาณ 1.18 และ 1.10 ตามลำดับ ซึ่งสามารถยืนยันว่าโมเดลมีการเรียนรู้ได้อย่างมีประสิทธิภาพ

4.3 การประเมินประสิทธิภาพการตรวจจับวัตถุ


4.3.1 mAP (Mean Average Precision)



ภาพที่ 8 mAP curves (Val)

จากกราฟนี้แสดงให้เห็นถึงความสามารถในการตรวจจับวัตถุของโมเดลบนชุดข้อมูล Validation ตลอด 20 Epochs โดยใช้ตัวชี้วัดหลักสองตัวคือ mAP50 เส้นสีน้ำเงิน ซึ่งวัดความแม่นยำที่เงื่อนไข IoU 50% และ mAP50-95 เส้นสีส้ม ซึ่งวัดความแม่นยำเฉลี่ยในช่วง IoU 50% ถึง 95% จะเห็นได้ว่า mAP50 มีค่าสูงมากและค่อนข้างคงที่ในช่วง 0.85 ถึง 0.91 ตลอดการฝึก ซึ่งบ่งบอกว่าโมเดลระบุตำแหน่งวัตถุได้ถูกต้อง แต่ค่า mAP50-95 นั้นเริ่มต้นที่ต่ำกว่าและค่อยๆ เพิ่มขึ้นอย่างสม่ำเสมอจนถึงประมาณ 0.61 ซึ่งแสดงถึงความสามารถของโมเดลในการระบุขอบเขตวัตถุได้อย่างแม่นยำสูง

4.3.2 Precision และ Recall




ภาพที่ 9 Validation Precision/ Recall

จากกราฟนี้แสดงให้เห็นถึงค่า Precision และค่า Recall ของโมเดลบนชุดข้อมูล Validation ตลอด 20 Epochs โดยค่า precision (เส้นสีน้ำเงิน) บ่งชี้ว่าการทำนายที่เป็นบวกของโมเดลนั้นถูกต้อง มีค่าสูงมาก และค่อนข้างคงที่ โดยส่วนใหญ่อยู่ในระดับ 0.90 ถึง 0.93 ซึ่งหมายความว่าเมื่อโมเดลตรวจจับ โอกาสที่การตรวจจับนั้นจะถูกต้องมีสูงมาก ในขณะที่ค่า recall (เส้นสีส้ม) แสดงให้เห็นว่าโมเดลสามารถตรวจจับ และมีแนวโน้มเพิ่มขึ้นอย่างต่อเนื่อง จากประมาณ 0.72 เป็นประมาณ 0.84 แม้ว่า Recall จะมีความผันผวนมากกว่า แต่การที่ค่า Precision สูง และค่า Recall เพิ่มขึ้นเรื่อยๆ แสดงให้เห็นว่าแบบจำลองมีการปรับปรุงความสามารถในการค้นหาวัตถุให้ครบถ้วนโดยยังคงรักษาความแม่นยำของการทำนายให้อยู่ในระดับสูงไว้ได้


4.4 การประเมินประสิทธิภาพการจำแนกประเภท

4.4.1 Confusion Matrix



ตารางที่ 4 Confusion Matrix

Confusion Matrix นี้แสดงให้เห็นว่าโมเดลทำนายคลาส “safety-helmet” ได้ถูกต้องสูงถึง 4,133 ครั้ง และไม่สามารถตรวจจับคลาส ‘no-helmet’ ได้เลย และมีความสับสนสูงระหว่างคลาส “safety-helmet” กับ “background” (รวมกัน) โดยทำนายผิดพลาดไปรวมกว่า 1,177 ครั้ง ($696 + 481$) ซึ่งบ่งชี้ว่าโมเดลทำงานได้ดีกับคลาส “safety-helmet”



ตารางที่ 5 Normalized Confusion Matrix

Normalized Confusion Matrix นี้แสดงให้เห็นว่าโมเดลทำนายว่าเป็นคลาส “background” (รวมกัน) จริงๆ นั้นเป็น “safety-helmet” ทั้งหมด (1.00) ซึ่งทำให้เกิด False Positives จำนวนมาก นอกจากนี้ เมื่อมี “safety-helmet” จริง แบบจำลองก็ทำนายได้ถูกต้อง 86% (0.86) เท่านั้น ส่วนอีก 14% (0.14) ถูกทำนายว่าเป็น “background” (รวมกัน)

4.5 ผลการทดสอบการทำงานของระบบในสภาพแวดล้อมจริง (System Integration and Real-Time Testing)

4.5.1 ความเร็วในการประมวลผล (Processing Speed - FPS)

ระบุว่าระบบสามารถประมวลผลได้กี่ เฟรมต่อวินาที (Frames Per Second - FPS) เพื่อยืนยันว่าสามารถใช้งานแบบ Real-time ได้



ภาพที่ 10 Processing Speed - FPS

4.5.2 ผลการทำงานในสถานการณ์ต่างๆ

แสดงตัวอย่างผลลัพธ์การตรวจจับใน สภาพแวดล้อมที่ท้าทาย (เช่น แสงน้อย , มุมกล้องที่แตกต่างกัน,การบดบังบางส่วน)




ภาพที่ 11 สถานการณ์ที่มีสภาพแวดล้อมในที่แสงน้อย



ภาพที่ 12 มุมกล้องที่แตกต่างกัน

4.5.3 ข้อผิดพลาดที่เกิดขึ้น (Failure Cases/Limitations)

ตัว Model เกิดอาการ Error หรือ Ghost Detect ที่ทำให้ตัวกล้องมีการตรวจจับสิ่งที่ไม่ควรจะตรวจจับได้เช่น จากภาพด้านล่างจะเห็นได้ว่า ไม่มีใครอยู่ใน frame เลยแต่ระบบกลับตรวจพบเจอว่ามีคนอยู่ในภาพ



ภาพที่ 13 ข้อผิดพลาดที่เกิดขึ้น

บทที่ 5

สรุปผลการวิจัย อภิปราย และข้อเสนอแนะ

5.1 สรุปผลการวิจัย

โครงการนี้มีวัตถุประสงค์เพื่อพัฒนาระบบตรวจจับการสวมหมวกนิรภัย (Helmet / No-Helmet) ในสภาพแวดล้อมโรงงานอุตสาหกรรมแบบ Real-time โดยประยุกต์ใช้เทคนิคการเรียนรู้เชิงลึก (Deep Learning) สำหรับการตรวจจับวัตถุ (Object Detection) ผ่านแบบจำลอง YOLO (You Only Look Once) ซึ่งเป็นสถาปัตยกรรมการตรวจจับแบบ One-stage Detector ที่สามารถประมวลผลได้อย่างรวดเร็วและมีความแม่นยำสูง

ในการดำเนินการ ผู้วิจัยได้เลือกใช้แบบจำลอง YOLOv8 ซึ่งเป็นรุ่นล่าสุดของตระกูล YOLO ที่ได้รับการปรับปรุงทั้งในด้านโครงสร้างโมเดลและขั้นตอนการฝึกสอน โดยใช้แนวทาง Transfer Learning และ Fine-tuning จากแบบจำลองที่ผ่านการฝึกมาก่อน (Pre-trained Model) บนชุดข้อมูลมาตรฐานสาธารณะ เช่น COCO Dataset ร่วมกับข้อมูลภาพที่ผู้วิจัยเก็บรวบรวมเพิ่มเติมจากสภาพแวดล้อมจริงภายในโรงงานอุตสาหกรรม เพื่อให้โมเดลสามารถเรียนรู้ลักษณะเฉพาะของพื้นที่และสภาพการทำงานจริงได้อย่างเหมาะสม

หลังจากการฝึกสอนโมเดล ผลการประเมินประสิทธิภาพแสดงให้เห็นว่าแบบจำลองที่พัฒนาได้ค่า Precision = 0.933 , Recall = 0.840 , mAP@50 = 0.914 , และ mAP@50-95 = 0.611 ซึ่งสะท้อนให้เห็นว่าโมเดลมีความสามารถสูงในการตรวจจับและจำแนกบุคคลากรที่สวมหมวกนิรภัยและไม่สวมหมวกนิรภัยได้อย่างถูกต้องในเวลาจริง ทั้งยังสามารถประมวลผลได้อย่างมีประสิทธิภาพภายใต้ข้อจำกัดของสภาพแวดล้อมในโรงงาน

นอกจากนี้ จากการเปรียบเทียบการตรวจจับระหว่างวิธีการสังเกตด้วยสายตาของเจ้าหน้าที่ความปลอดภัยกับระบบที่พัฒนาขึ้น พบว่า ระบบตรวจจับอัตโนมัติที่ใช้โมเดล YOLOv8 สามารถ ลดระยะเวลาในการตรวจสอบจากเฉลี่ย 30 วินาทีต่อคน เหลือเพียงประมาณ 5 วินาทีต่อคน โดยยังคงความแม่นยำในการตรวจจับได้อย่างมีประสิทธิภาพ การลดเวลานี้ช่วยเพิ่มประสิทธิภาพการทำงานของเจ้าหน้าที่ด้านความปลอดภัย ลดภาระงานและความผิดพลาดจากมนุษย์ (Human Error) อีกทั้งยังเพิ่มศักยภาพของระบบเฝ้าระวังแบบอัตโนมัติให้สามารถนำไปใช้ในสถานประกอบการจริงได้อย่างยั่งยืน

5.2 ปัญหาที่พบ

ในระหว่างการสร้างโมเดล และทำการทดลอง พบว่า

1. การรวบรวมข้อมูลสำหรับการฝึกสอนโมเดลมีจำนวนจำกัด ส่งผลให้โมเดลมีขีดความสามารถในการเรียนรู้เพื่อจำแนกและตรวจจับใบหน้า รวมถึงการสวมหมวกนิรภัยได้อย่างจำกัด
2. พื้นที่และสภาพการติดตั้งกล้องมีผลต่อประสิทธิภาพการตรวจจับ หากกล้องมีความละเอียดต่ำ แสงไม่เพียงพอ หรือมุมกล้องไม่เหมาะสม เช่น ถ่ายจากมุมเฉียงหรือห่างเกินไป อาจทำให้โมเดลตรวจจับใบหน้าและการสวมหมวกได้ไม่ถูกต้อง

5.3 ข้อเสนอแนะ

ในโครงการฉบับนี้ยังคงมีพื้นที่สำหรับการพัฒนาต่อยอดได้ดังนี้

1. การเพิ่มการแจ้งเตือนเข้าไปหาหัวหน้าแผนก เพื่อบันทึกว่าพนักงานท่านใดที่สวมใส่หมวกนิรภัย หรือ ไม่สวมใส่หมวกนิรภัย
2. การเพิ่มระบบตรวจจับกับระบบควบคุมความปลอดภัยของโรงงาน เพื่อยกระดับการจัดการด้านความปลอดภัยให้มีประสิทธิภาพมากยิ่งขึ้น โดยสามารถประสานการทำงานร่วมกับระบบควบคุมการเข้า และออกพื้นที่หรือระบบควบคุมการเปิด และปิดประตูอัตโนมัติ เพื่อใช้ในการจำกัดการเข้าพื้นที่ เมื่อมีการตรวจพบว่าพนักงานไม่ได้สวมหมวกนิรภัยหรือคนที่เข้ามาไม่ใช่พนักงาน ซึ่งจะช่วยเสริมสร้างมาตรการความปลอดภัยเชิงป้องกัน และลดความเสี่ยงจากอุบัติเหตุที่ไม่เป็นไปตามข้อกำหนดได้อย่างมีประสิทธิภาพ

5.4 ข้อจำกัด

การตั้งค่าตำแหน่งกล้องที่ไม่เหมาะสมในบางจุด (เช่น สูงเกินไปหรือมุมเฉียงมาก) ทำให้เห็นส่วนศีรษะไม่ชัด ส่งผลต่อการแยกแยะการสวมหมวก

เอกสารอ้างอิง

- [1] Y. Lecun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proc. IEEE*, vol. 86, no. 11, pp. 2278–2324, Nov. 1998, doi: 10.1109/5.726791.
- [2] "ImageNet Classification with Deep Convolutional Neural Networks," *ResearchGate*, Aug. 2025, doi: 10.1145/3065386.
- [3] "(PDF) Evaluation of Pooling Operations in Convolutional Architectures for Object Recognition," *ResearchGate*, Aug. 2025, doi: 10.1007/978-3-642-15825-4_10.
- [4] V. Nair and G. E. Hinton, "Rectified Linear Units Improve Restricted Boltzmann Machines".
- [5] "(PDF) Ian Goodfellow, Yoshua Bengio, and Aaron Courville: Deep learning: The MIT Press, 2016, 800 pp, ISBN: 0262035618," *ResearchGate*, doi: 10.1007/s10710-017-9314-z.
- [6] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," May 09, 2016, *arXiv*: arXiv:1506.02640. doi: 10.48550/arXiv.1506.02640.
- [7] J. Redmon and A. Farhadi, "YOLO9000: Better, Faster, Stronger," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, July 2017, pp. 6517–6525. doi: 10.1109/CVPR.2017.690.
- [8] J. Redmon and A. Farhadi, "YOLOv3: An Incremental Improvement," Apr. 08, 2018, *arXiv*: arXiv:1804.02767. doi: 10.48550/arXiv.1804.02767.
- [9] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, "YOLOv4: Optimal Speed and Accuracy of Object Detection," Apr. 23, 2020, *arXiv*: arXiv:2004.10934. doi: 10.48550/arXiv.2004.10934.
- [10] "Computer Vision: Algorithms and Applications | SpringerLink." Accessed: Oct. 17, 2025. [Online]. Available: <https://link.springer.com/book/10.1007/978-3-030-34372-9>
- [11] D. Marr, *Vision: a computational investigation into the human representation and processing of visual information*. Cambridge, Mass: MIT Press, 2010.
- [12] L. Deng, J. Zhou, and Q. Liu, "Helmet Net: An Improved YOLOv8 Algorithm for Helmet Wearing Detection," *Int. J. Networked Distrib. Comput.*, vol. 12, no. 2, pp. 329–343, Dec. 2024, doi: 10.1007/s44227-024-00040-1.
- [13] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," *Inf. Process. Manag.*, vol. 45, no. 4, pp. 427–437, July 2009, doi: 10.1016/j.ipm.2009.03.002.
- [14] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, "The Pascal Visual Object Classes (VOC) Challenge," *Int. J. Comput. Vis.*, vol. 88, no. 2, pp. 303–338, June 2010, doi: 10.1007/s11263-009-0275-4.
- [15] "(PDF) Data Science for Business," *ResearchGate*. Accessed: Oct. 17, 2025. [Online]. Available: https://www.researchgate.net/publication/256438799_Data_Science_for_Business
- [16] S. Zhang and X. Li, "A comparative study of machine learning regression models for predicting construction duration," *J. Asian Archit. Build. Eng.*, vol. 23, no. 6, pp. 1980–1996, Nov. 2024, doi: 10.1080/13467581.2023.2278887.